

Corpora, Classificação e Similaridade de Texto

Introdução ao Processamento de Linguagem Natural

Ana Carolina Poletto, Bárbara Dapper, João Pedro Martins, Luiza Pasini e Rafaela Remião

Introdução

Conseguimos saber de qual área é uma questão de concurso só pelo texto? O quanto os modelos de linguagem concordam com a gente?

Corpus de Questões

Coleta

95 provas de TI da banca FGV, no PCI Concursos, de 2021 a 2026

727

Engenharia de Software

669

Redes e Infraestrutura


502

Segurança da
Informação

**As 3 subáreas exigidas passam de 500 · BD (469) e Governança (139) são extras ·
total: 2.506 questões**

Do PDF ao JSON

etapas aplicadas em cada prova



6.777 questões extraídas → 2.506 no corpus

O que foi descartado

Critérios de exclusão

- Não é de computação (português, direito...)
- Problema de conversão (símbolo, tabela, figura)
- Alternativa faltando ou questões grudadas
- Sem gabarito ou anulada
- Repetida em outra prova

4.271

questões removidas
63% do total extraído

Como definimos a subárea

classificação automática, em duas etapas

Palavras-chave

lista de termos por subárea;
o enunciado vale o dobro

Ambíguas

11% das questões têm
menos de 4 pontos entre a
1ª e a 2ª subárea

k-NN (k=3)

treinado nas questões
confiáveis, decide as
ambíguas

Conferimos 100 questões sorteadas: 97 estavam na subárea certa

Estrutura do JSON

```
{
  "id": "28-061",
  "subarea": "seguranca_da_informacao",
  "ano": 2023,
  "banca": "FGV",
  "cargo_orgao": "analista_judiciario ... tj se",
  "enunciado": "O computador de Elias foi ...",
  "alternativas": [
    {"letra": "A", "texto": "memória;"}, ...
  ],
  "gabarito": "A",
  "resposta_correta": "memória;"
}
```

Estatísticas do corpus

Subárea	Questões	Provas	Anos	Tokens / enunciado
Eng. de Software	727	74	2021–2026	66,8
Redes e Infra	669	80	2021–2026	65,8
Segurança	502	81	2021–2026	69,3
Banco de Dados	469	77	2021–2026	66,2
Governança	139	50	2021–2026	64,3
Total	2.506	91	2021–2026	66,8

Dataset card

Fonte

PCI Concursos, banca FGV,
2021–2026

Tamanho

2.506 questões, 5 subáreas,
91 provas

Formato

JSON, CSV e um TXT por
questão

Uso

classificar por subárea e
responder questões

Limitações


Governança só com 139;
~3% com subárea errada

Qualidade

94,7% das palavras estão
no dicionário

Corpus de Similaridade

Das questões aos pares de palavras



200 palavras distintas → 100 pares anotados de 1 a 5

Escala de similaridade

Nota	Na escala da aula	Significado
1	0	nenhuma semelhança de significado
2	0,25	baixa: ligação só de tema ou função
3	0,5	moderada: propriedades em comum
4	0,75	alta: significados próximos
5	1	muito alta: sinônimos

Concordância entre anotadores

2 alunas (Luiza e Rafaela) anotaram os 100 pares sem ver as notas uma da outra

0,79

Kappa de Cohen ponderado (linear)

0,83

Correlação de Spearman

Mesma nota em 89 pares; nos outros 11, diferença de 1 ponto. 66 pares tiveram nota mínima das duas: o sorteio gerou poucos pares parecidos.

Formato do CSV

```
id_par,palavra_1,palavra_2,nota_1,nota_2,similaridade_media  
P001,ferramenta,plataforma,3,3,3.0  
P002,criptografia,chamar,1,1,1.0  
P004,protocolo,segurança,2,2,2.0  
...  
(também: nome das anotadoras, mediana, amplitude e revisar)
```

Dataset card da similaridade

Fonte

200 lemas do corpus de questões

Tamanho

100 pares, 2 anotadoras

Formato

CSV com as notas, média e mediana

Uso

comparar modelos com a percepção humana

Limitações

pares sorteados: 66 com nota mínima

Qualidade

kappa linear de 0,79 entre as anotadoras

Classificação de Texto

Três formas de representar o texto

mesmos classificadores, mesma divisão treino/teste

BoW + TF-IDF

contagem de palavras com
peso pela raridade

spaCy

pt_core_news_lg
média dos vetores das
palavras

BERT

BERTimbau (português)
média dos tokens da última
camada

k-NN (k=3, como na aula) e regressão logística · treino/teste 80/20 estratificado · F1-macro

Parâmetros do TF-IDF

Parâmetro	Valor	Por quê
max_features	10.000	testamos de 200 até todas; estabiliza perto de 5 mil
stop_words	spaCy	igual à aula; melhora um pouco o F1
ngram_range	(1, 1)	bigramas pioram o k-NN
max_df	1,0	0,8 (da aula) não muda nada
sublinear_tf	True	log da contagem, como na aula

Resultados

conjunto de teste, 502 questões · regressão logística, e o k-NN na última coluna

Representação	Acurácia	F1-macro	F1 com k-NN
BoW + TF-IDF	0,912	0,910	0,881
spaCy pt_core_news_lg	0,851	0,832	0,426
BERTimbau	0,813	0,804	0,753

Por que o TF-IDF ganhou

Vantagens do TF-IDF

- Termos técnicos decidem a subárea (SELECT, ITIL, IPsec)
- O TF-IDF dá peso direto aos termos raros
- Os rótulos também vieram de palavras-chave

Problemas dos embeddings

- A média dos vetores dilui os termos técnicos
- k-NN com spaCy desaba (F1 0,43)
- BERT sem ajuste: vetor genérico da frase
- Das 26 questões que todos erram, várias têm rótulo errado

Similaridade de Palavras

Como medimos

nota do modelo vs. nota humana, na escala da aula (0 a 1)

spaCy

cosseno entre os vetores
das duas palavras

BERT

cosseno entre os vetores de
cada palavra (média dos
subtokens)

LLM

Gemini 3.5 Flash dá um grau
de 0 a 1, com os exemplos
da aula

Comparação com Spearman, nos dois datasets: o nosso e o feito em aula

Resultados

correlação de Spearman com a anotação humana

Modelo	Nosso dataset	Dataset da aula
spaCy pt_core_news_lg	0,30	0,07
BERTimbau	0,23	0,11
LLM (Gemini)	0,68	0,53
Concordância humana	0,83	0,35 a 0,40

O Gemini é o único perto das pessoas; no dataset de aula, até as alunas concordam pouco entre si.

Três pares que explicam

nota das pessoas e de cada modelo

tcp / ordem

peessoas 0,25 · spaCy 0,04
BERT 0,40 · Gemini 0,50

deployar / publicar

peessoas 1 · spaCy 0
BERT 0,41 · Gemini 0,75

vetor / matriz

peessoas 0 · spaCy 0,37
BERT 0,78 · Gemini 0,75

Só o Gemini usa o sentido das palavras em TI, mas todos acham vetor e matriz parecidos

Análise crítica

O que funcionou

- TF-IDF acertou 91% das subáreas
- Gemini concordou com as anotadoras (0,68)
- k-NN da aula decidiu os rótulos ambíguos
- Mesma escala nos dois datasets

Limitações

- Só 2 anotadoras e 100 pares, quase todos pouco parecidos
- Palavras técnicas fora do vocabulário do spaCy
- BERT não foi feito para palavra isolada
- Cerca de 3% das questões com subárea errada

Uso de IA

Onde usamos

- Claude: programação dos scripts e notebooks
- Claude: texto do README e da apresentação
- Claude: conferência das 336 questões usadas para medir a subárea
- Codex: scripts da parte 2
- Gemini: um dos modelos testados na parte 4

Onde não usamos

- Anotação dos 100 pares (Luiza e Rafaela)
- Anotação do dataset de aula
- Nenhum rótulo do corpus veio da conferência com IA

Conclusões

Para classificar, o TF-IDF foi o melhor (F1 0,91): o assunto está nos termos técnicos. Para similaridade, só o LLM ficou perto das pessoas.