

Corpora, Classificação e Similaridade de Texto

Introdução ao Processamento de Linguagem Natural

Ana Carolina Poletto, Bárbara Dapper, João Pedro Martins, Luiza Pasini e Rafaela Remião

Introdução

Conseguimos saber de qual área é uma questão de concurso só pelo texto? O quanto os modelos de linguagem concordam com a gente?

Corpus de Questões

Coleta

95 provas de TI da banca FGV, no PCI Concursos, de 2021 a 2026

727

Engenharia de
Software

669


Redes e
Infraestrutura

502

Segurança da
Informação

Do PDF ao JSON

etapas aplicadas



6.777 questões extraídas → 2.506 no corpus

Critérios de exclusão

Foram removidas **4.271 questões (63% do total)** por estarem fora da área de Computação, apresentarem **problemas de conversão ou formatação**, estarem **sem gabarito ou anuladas**, ou serem **repetidas em outras provas**.

Definição de subárea

Palavras-chave

lista de termos por subárea, o enunciado vale o dobro

Ambíguas

11% das questões têm menos de 4 pontos entre a 1ª e a 2ª subárea

k-NN (k=3)

treinado nas questões confiáveis, decide as ambíguas

Estrutura do JSON

```
{  
  "id": "28-061",  
  "subarea": "seguranca_da_informacao",  
  "ano": 2023,  
  "banca": "FGV",  
  "cargo_orgao": "analista judiciario ... tj se",  
  "enunciado": "0 computador de Elias foi ...",  
  "alternativas": [  
    {"letra": "A", "texto": "memória;"}, ...  
  ],  
  "gabarito": "A",  
  "resposta_correta": "memória;"  
}
```

Estatísticas do corpus

Subárea	Questões	Provas	Anos	Tokens / enunciado
Eng. de Software	727	74	2021–2026	66,8
Redes e Infra	669	80	2021–2026	65,8
Segurança	502	81	2021–2026	69,3
Banco de Dados	469	77	2021–2026	66,2
Governança	139	50	2021–2026	64,3
Total	2.506	91	2021–2026	66,8

Dataset card

Fonte

PCI Concursos, banca
FGV, 2021–2026

Tamanho

2.506 questões, 5
subáreas, 91 provas

Formato

JSON, CSV e um TXT
por questão

Uso


classificar por subárea
e responder questões

Qualidade

94,7% das palavras
estão no dicionário

Corpus de Similaridade

Das questões aos pares de palavras



200 palavras distintas → 100 pares anotados de 1 a 5

Escala de similaridade

Nota	Na escala da aula	Significado
1	0	nenhuma semelhança de significado
2	0,25	baixa: ligação só de tema ou função
3	0,5	moderada: propriedades em comum
4	0,75	alta: significados próximos
5	1	muito alta: sinônimos

Concordância entre anotadores

2 alunas (Luiza e Rafaela) anotaram os 100 pares sem ver as notas uma da outra

0,79

Kappa de Cohen
ponderado (linear)

0,83

Correlação de
Spearman

Mesma nota em 89 pares; nos outros 11, diferença de 1 ponto. 66 pares tiveram nota mínima das duas: o sorteio gerou poucos pares parecidos.

Formato do CSV

```
id_par,palavra_1,palavra_2,nota_1,nota_2,similaridade_media
```

```
P001,ferramenta,plataforma,3,3,3.0
```

```
P002,criptografia,chamar,1,1,1.0
```

```
P004,protocolo,segurança,2,2,2.0
```

```
...
```

```
(também: nome das anotadoras, mediana,  
amplitude e revisar)
```

Dataset card da similaridade

Fonte

200 lemas do corpus
de questões

Tamanho

100 pares, 2
anotadoras

Formato

CSV com as notas,
média e mediana

Uso

comparar modelos com
a percepção humana

Limitações

pares sorteados: 66
com nota mínima

Qualidade

kappa linear de 0,79
entre as anotadoras

Classificação de Texto

Três formas de representar o texto

mesmos classificadores, mesma divisão treino/teste

BoW + TF-IDF

contagem de
palavras com peso
pela raridade

spaCy

pt_core_news_lg
média dos vetores
das palavras

BERT

BERTimbau
média dos tokens da
última camada

k-NN (k=3, como na aula) e regressão logística · treino/teste 80/20 estratificado · F1-macro

Parâmetros do TF-IDF

Parâmetro	Valor	Por quê
max_features	10.000	testamos de 200 até todas; estabiliza perto de 5 mil
stop_words	spaCy	igual à aula; melhora um pouco o F1
ngram_range	(1, 1)	bigramas pioram o k-NN
max_df	1,0	0,8 (da aula) não muda nada
sublinear_tf	True	log da contagem, como na aula

Resultados

conjunto de teste, 502 questões · regressão logística, e o k-NN na última coluna

Representação	Acurácia	F1-macro	F1 com k-NN
BoW + TF-IDF	0,912	0,910	0,881
spaCy pt_core_news_lg	0,851	0,832	0,426
BERTimbau	0,813	0,804	0,753

Por que o TF-IDF ganhou

Vantagens do TF-IDF

Termos técnicos decidem a subárea (SELECT, ITIL, IPSec)

O TF-IDF dá peso direto aos termos raros

Os rótulos também vieram de palavras-chave

Problemas dos embeddings

A média dos vetores dilui os termos técnicos

k-NN com spaCy desaba

BERT sem ajuste: vetor genérico da frase

Das 26 questões que todos erram, várias têm rótulo errado

Similaridade de Palavras

Como medimos

nota do modelo vs. nota humana, na escala da aula (0 a 1)

spaCy

cosseno entre os
vetores das duas
palavras

BERT

cosseno entre os
vetores de cada palavra
(média dos subtokens)

LLM

Gemini 3.5 Flash dá um
grau de 0 a 1, com os
exemplos da aula

Comparação com Spearman, nos dois datasets: o nosso e o feito em aula

Resultados

correlação de Spearman com a anotação humana

Modelo	Nosso dataset	Dataset da aula
spaCy pt_core_news_lg	0,30	0,07
BERTimbau	0,23	0,11
LLM (Gemini)	0,68	0,53
Concordância humana	0,83	0,35 a 0,40

O Gemini é o único perto das pessoas; no dataset de aula, até as alunas concordam pouco entre si.

Três pares que explicam

nota das pessoas e de cada modelo

tcp / ordem

peessoas 0,25 · spaCy 0,04
BERT 0,40 · Gemini 0,50

deployar / publicar

peessoas 1 · spaCy 0
BERT 0,41 · Gemini 0,75

vetor / matriz

peessoas 0 · spaCy 0,37
BERT 0,78 · Gemini 0,75

Só o Gemini usa o sentido das palavras em TI, mas todos acham vetor e matriz parecidos

O que funcionou

O TF-IDF classificou certo **91% das questões**, porque os termos técnicos decidem a subárea. Na similaridade, **o Gemini foi o modelo mais perto das pessoas** (0,68 no nosso dataset). E o **k-NN visto em aula** resolveu as questões ambíguas na hora de definir a subárea.

Limitações

Só 2 anotadoras e 100 pares, quase todos pouco parecidos. O spaCy não conhece termos como **deployar e parsear**, o BERT não foi feito para **palavras isoladas**, e cerca de **3% das questões** ainda estão com a subárea errada.

Conclusões

Para classificar, o TF-IDF foi o melhor (F1 0,91), o assunto está nos termos técnicos. Para similaridade, só o LLM ficou perto das pessoas.